

Arquitetura de um sistema de BI conversacional

Agentes de LLM, texto-para-SQL e governança de dados aplicados ao fomento à pesquisa

PERGUNTA

em português, sem SQL

CONSULTA VALIDADA

somente leitura, com limite

RESPOSTA COM ORIGEM

texto, tabela, gráfico e o SQL

EQUIPE

Eduardo Neuman • Eduardo Oliveira • Felipe Costabeber • Guilherme Souza • Luiz Rojas • Moisés Omena • Tadeu Augusto

Estrutura da apresentação em três partes

I Introdução

- O problema de acesso, a proposta e a hipótese de trabalho

II Desenvolvimento

- Visão geral da arquitetura
- Camada de dados: ETL e modelo dimensional
- Orquestração multiagente com LangGraph
- Agentes de SQL e o protocolo MCP
- Anatomia de uma pergunta, fim a fim
- Funcionalidades: painéis, relatórios e slides

III Conclusão


- Síntese, trabalhos futuros e referências

A apresentação parte do problema de negócio, desce camada por camada até a arquitetura que o executa e fecha com o que ficou em aberto.

O acesso aos dados de gestão depende de intermediação técnica

A FAPES financia pesquisa no Espírito Santo por meio de editais, projetos e bolsas, e registra cada pagamento em sistema próprio. O dado existe, mas quem decide não chega até ele sozinho: cada pergunta precisa ser traduzida para SQL por um analista, executada no banco e devolvida em planilha.


CADEIA ATUAL



O percurso leva dias e depende da agenda de terceiros, o que restringe o uso a perguntas já consolidadas. Cada repetição abre espaço para leituras diferentes da mesma pergunta, porque «investimento» e «quantidade de bolsas» não têm definição única no próprio sistema.

HIPÓTESE DE TRABALHO


Restrito a um esquema dimensional único e a uma base de conhecimento recuperável, um modelo de linguagem traduz perguntas de gestão em consultas corretas e rastreáveis, dispensando os três elos intermediários.



A INTERFACE PROPOSTA

A pergunta escrita em português substitui o pedido ao analista. O sistema decide se ela exige dados, gera e valida o SQL, executa em modo somente-leitura e devolve texto, tabela e gráfico, expondo a consulta usada.


Visão de contêineres: do navegador ao banco de dados



Do sistema transacional ao esquema estrela e à view de consulta



ESQUEMA ESTRELA • GRÃO DO FATO



A DECISÃO DE PROJETO

A consulta ocorre sobre uma única view

Sobre o esquema estrela é materializada uma view que já resolve as chaves em texto: `NomeEdital`, `AreaTecnica`, `DescricaoModalidade`, `Ano`, `DescricaoStatus`. O modelo enfrenta um problema menor, filtrar e agregar uma tabela, em vez de escolher caminhos de junção.

O QUE SE GANHA E O QUE SE PERDE

GANHO

O modelo filtra e agrega uma tabela só: menos SQL inválido, menor latência e prompt de sistema mais curto.


LIMITE

A view responde por pagamentos de bolsa por mês. Perguntas fora desse recorte exigem nova modelagem no dbt.

A base transacional segue disponível para o modo de conferência: a mesma pergunta é respondida pelos dois lados e os resultados comparados.

Orquestração em grafo de estados

GRAFO DO ORQUESTRADOR • LANGGRAPH



ESTADO COMPARTILHADO

Um único objeto `MultiAgentState` atravessa os nós: histórico, tenant e esquema, modo de dados, modo rápido, escopo do relatório, dados coletados e lacunas pendentes. O estado é persistido em Redis por `thread_id`, o que permite retomar uma conversa.

POR QUE UM GRAFO

- **Rotas heterogêneas.** Uma saudação e um pedido de comparação plurianual entram pela mesma interface e seguem caminhos distintos.
- **Paralelismo.** Quando o roteador emite várias chamadas, elas são despachadas simultaneamente.
- **Laço controlado.** A reflexão pode solicitar nova rodada de consultas, limitada a duas iterações para conter a latência.
- **Observabilidade.** Cada nó emite um evento de status, que vira a linha de raciocínio exibida ao usuário.

Pipeline de geração de SQL, da pergunta ao resultado

AGENTE OLAP • DA PERGUNTA REESCRITA AO RESULTADO FORMATADO

1 Reescrita da pergunta

Normaliza a formulação coloquial para os termos do modelo de dados.

2 Resolução semântica de valores

Busca no pgvector converte «conectafapes» no nome exato do projeto.

3 Recuperação de conhecimento

Traz o DDL da view, as regras de negócio e exemplos próximos.

4 Geração do SQL

Saída estruturada com consulta, explicação e o formato de cada coluna retornada.

5 Validação

Análise sintática, lista de bloqueio e execução simulada com **EXPLAIN** antes de tocar nos dados.

6 Correção realimentada

Se a validação falhar, o erro volta ao modelo como contexto para nova tentativa.

7 Formatação da resposta

Valores em português, rótulos de negócio e sugestão de desdobramento.

EXEMPLO • DA PERGUNTA AO SQL GERADO

«Qual a distribuição de bolsas pagas em 2025, por modalidade?»

```
SELECT sigla, descricaomodalidade,  
       COUNT(DISTINCT idpagamentooriginalfk)  
FROM vfactpagamentoresolved  
WHERE descricaostatus = 'PAGO'  
AND ano = 2025  
GROUP BY sigla, descricaomodalidade
```

O QUE A VALIDAÇÃO RECUSA

- Escrita de qualquer tipo. **INSERT**, **UPDATE**, **DELETE**, **DROP** e comandos de definição.
- Mais de uma instrução na mesma consulta, o vetor clássico de injeção.
- Tabelas fora da view autorizada e funções de sistema do PostgreSQL.
- Consultas que não passam no **EXPLAIN**, verificado antes de tocar nos dados.

Percurso de uma pergunta, da requisição à resposta

«Qual foi o investimento em bolsas por área técnica em 2025?»

O QUE ACONTECE EM SEGUIDA

1 Autenticação e persistência

Token validado, conversa gravada e fluxo SSE aberto antes de a resposta existir.

2 Roteamento

O orquestrador classifica: pede dados, e não exige relatório.

3 Delegação

Instrução autossuficiente vai à ferramenta `sql_agent` via MCP.

4 Consulta


SQL gerado, validado e executado com papel somente leitura e limite de tempo.

5 Redação

A resposta é escrita em linguagem de negócio, com o valor em destaque.

6 Entrega

Texto, tabela, gráfico, SQL e passos são persistidos e exibidos.




Cada evento de status emitido pelos nós do grafo é guardado junto da mensagem. Ao recarregar a página, a linha de raciocínio continua lá, e a rastreabilidade não depende da sessão do navegador.

Formatos de saída: painel, relatório e apresentação

PAINÉIS

Fixação de respostas como indicadores

Qualquer resposta pode ser fixada como indicador. Os blocos são redimensionáveis e reposicionáveis, com recorte próprio e cache de quatro horas.



RELATÓRIOS

Seções definidas por pergunta

O roteiro das seções é gerado para cada pergunta. Percentuais, variações e destaques são calculados em código; ao modelo cabe apenas redigir sobre números já prontos.



APRESENTAÇÕES

Slides em PDF e PowerPoint

Roteiro, consulta paralela dos dados, redação e renderização. Cores, tipografia e regras de gráfico vêm de um arquivo único de tokens, compartilhado por ambos os formatos.



Síntese e desdobramentos

SÍNTESE

RESULTADO

Perguntas de gestão formuladas em português são respondidas com dados reais em poucos segundos, sem intermediação técnica.

FATORES DE CONFIABILIDADE

View única, validação antes da execução, papel sem permissão de escrita e separação de processos tiveram mais efeito que ajustes de prompt.

RASTREABILIDADE

Cada resposta preserva a consulta executada, a origem dos dados e os passos do agente.

RESTRIÇÃO DOMINANTE

A dificuldade principal deixou de ser a geração de SQL e passou a ser a definição institucional dos termos.

TRABALHOS FUTUROS

CAMADA DE MÉTRICAS

Declarada e versionada acima da view, com definição única por indicador.

AVALIAÇÃO SISTEMÁTICA

Conjunto de referência e medida de acurácia de execução sobre perguntas conhecidas.

AMPLIAÇÃO DO MODELO DIMENSIONAL

Cobertura de auxílios, taxas e prestação de contas, hoje fora da base.